

Классификация финансовых трат на русском языке

Russian Expense Text Categorization

Разумовский Борис
NLP Course, Spring 2026
borispobeditelforever@gmail.com

Abstract

В данной работе рассматривается задача автоматической классификации коротких русскоязычных описаний финансовых трат по 9 категориям. Мы сформировали синтетический датасет из 995 размеченных примеров с помощью языковой модели GigaChat-2 и сравнили четыре подхода: правила (keyword matching), TF-IDF + логистическая регрессия, нулевое обучение (zero-shot) и малое обучение (few-shot) с GigaChat-2. TF-IDF+LR и few-shot достигают наивысшей точности 0.79 на тестовой выборке, превосходя zero-shot на 0.17 по accuracy. Few-shot примечателен тем, что достигает конкурентного качества без обучения классификатора.

1. Введение

Автоматическая категоризация финансовых транзакций — важная прикладная задача NLP. Приложения личных финансов, банковские системы и финтех-сервисы используют её для аналитики расходов, бюджетирования и персонализированных рекомендаций. Основная сложность задачи обусловлена краткостью записей (2–8 слов), неформальными сокращениями и аббревиатурами, а также богатой морфологией русского языка: одно слово может иметь десятки форм.

В настоящей работе мы формулируем задачу как многоклассовую классификацию: дана строка текста, нужно отнести её к одной из 9 категорий расходов. Мы собираем синтетический датасет, реализуем четыре подхода — от простых правил до few-shot LLM — и сравниваем их по метрикам accuracy и F1.

2. Related Work

Задача классификации коротких текстов изучалась в ряде работ. Joulin et al. [1] предложили FastText — эффективный метод на основе n-грамм слов и символов, достигающий конкурентного качества при малых вычислительных затратах. Zhang et al. [2] исследовали применение символьных сверточных сетей и показали их устойчивость к опечаткам и нестандартным написаниям.

Devlin et al. [3] представили BERT, который обеспечил качественный скачок в задачах классификации текста. Куратов и Архипов [4] адаптировали BERT для русского языка (ruBERT), обучив модель на русскоязычных корпусах. Тем не менее для очень коротких текстов (2–8 слов) дообучение BERT не всегда оправдано по соотношению качества и вычислительных затрат.

Brown et al. [5] в работе GPT-3 показали, что большие языковые модели способны решать задачи классификации в режиме few-shot — используя лишь несколько примеров в промпте без дообучения. Этот подход особенно привлекателен при ограниченных данных. GigaChat [6] — российская языковая модель Сбербанка, оптимизированная для русского языка и доступная через публичный API.

Задача категоризации банковских транзакций на русском языке остаётся малоизученной в открытой литературе. Коммерческие решения (Тинькофф, Сбер) используют проприетарные модели. Настоящая работа восполняет этот пробел, предлагая открытый датасет и сравнение подходов.

3. Датасет и постановка задачи

3.1 Постановка задачи

Задача: дано короткое русскоязычное описание финансовой траты (1–10 слов), необходимо отнести его к одной из 9 предопределённых категорий:

$Y = \{\text{еда, транспорт, кафе, здоровье, одежда, техника, подписки, развлечения, другое}\}.$

Формально: $f: X \rightarrow Y$, где X — пространство текстовых описаний трат.

3.2 Сбор данных

Датасет сгенерирован с помощью GigaChat-2 при температуре 0.7. Для каждой категории модели предлагалось сгенерировать 140 уникальных примеров в формате реальных пользовательских записей: "кофе в старбаксе", "такси до аэропорта", "продукты в пятерочке 1200р". Итого собрано 995 примеров. Разбивка: 80% train (796), 10% val (99), 10% test (100). Классы распределены неравномерно: от 66 (развлечения) до 140 (одежда, техника, другое) примеров.

Категория	Train	Val	Test	Всего
еда	74	9	10	93
транспорт	88	11	12	111
кафе	99	12	13	124
здоровье	73	9	9	91
одежда	112	14	14	140
техника	112	14	14	140
подписки	72	9	9	90
развлечения	52	7	7	66
другое	112	14	14	140
Итого	796	99	100	995

4. Подходы

4.1 Rule-based (Baseline 1)

Метод основан на словарях ключевых слов: для каждой из 8 основных категорий составлен список 20–30 характерных слов, названий брендов и мест. Классификатор подсчитывает совпадения и выбирает категорию с наибольшим числом вхождений. При отсутствии совпадений — "другое". Метод не требует данных, легко интерпретируем, но плохо обобщается на новые формулировки.

4.2 TF-IDF + Logistic Regression (Baseline 2)

Признаки: символьные n-граммы (2–4) с TF-IDF взвешиванием (50 000 признаков, `sublinear_tf=True`). Классификатор: мультиклассовая логистическая регрессия ($C=5.0$, `solver=lbfgs`). Символьные n-граммы учитывают морфологию и обрабатывают опечатки, что важно для неформальных пользовательских записей. Обучение занимает < 1 секунды на 796 примерах.

4.3 GigaChat Zero-shot (Competitive approach)

Модель GigaChat-2 получает описание траты и список из 9 категорий. Промпт: "Категоризируй запись X. Категории: ..., ответь одним словом." Обучающие примеры не предоставляются. Температура 0.1 для детерминированного вывода. Оценивается на 100

примерах из test-set.

4.4 GigaChat Few-shot (Proposed approach)

Расширение zero-shot: в промпт добавляется 3 размеченных примера для каждого класса (27 пар текст–категория), случайно выбранных из train-выборки. Few-shot примеры помогают модели разграничить близкие категории (например, "еда" vs "кафе"). Использует тот же GigaChat-2, ту же температуру 0.1. Не требует обучения модели — только доступа к API.

5. Результаты

Все методы оценивались по Accuracy и F1 (weighted average) на тестовой выборке (100 примеров). GigaChat-методы применялись к тем же 100 примерам (полный test-set). Rule-based и TF-IDF+LR также оценивались на полном test-set.

Подход	Accuracy	F1 (weighted)
Rule-based	0.4400	0.4494
TF-IDF + LR	0.7900	0.7897
GigaChat Zero-shot	0.6200	0.5891
GigaChat Few-shot	0.7900	0.7866

TF-IDF+LR и GigaChat Few-shot показывают одинаковую точность (0.79), значительно превосходя Rule-based (0.44) и GigaChat Zero-shot (0.62). Ключевой вывод: few-shot LLM достигает конкурентного качества без обучения классификатора, используя лишь несколько примеров в промпте. Низкий результат zero-shot объясняется неоднозначностью коротких записей — модель без примеров часто путает "еда" vs "кафе" и "развлечения" vs "другое".

6. Анализ ошибок

Главный источник ошибок у всех методов — пересечение категорий "еда" и "кафе": записи вида "доставка суши" или "пицца домой" одни классификаторы относят к "кафе", другие — к "еда". Аналогичная проблема у пар "развлечения"/"другое" и "одежда"/"техника" (аксессуары).

Rule-based ошибается на новых брендах и нестандартных формулировках, не включённых в словарь. TF-IDF+LR хорошо обобщается, но плохо работает на очень коротких (1–2 слова) и омонимичных записях. Few-shot GigaChat лучше всего справляется с пограничными случаями благодаря семантическому пониманию, однако медленнее всех из-за API-запросов.

7. Заключение

В работе решена задача классификации коротких русскоязычных описаний финансовых трат по 9 категориям. Собран синтетический датасет из 995 примеров с помощью GigaChat-2. Сравнены четыре подхода: rule-based, TF-IDF+LR, zero-shot LLM и few-shot LLM. Наилучшее качество (acc=0.79, F1=0.79) разделяют TF-IDF+LR и GigaChat Few-shot.

Практический вывод: для реального приложения TF-IDF+LR предпочтительнее (быстрее, дешевле, не требует API), однако few-shot LLM выгоден при необходимости расширять число категорий без переобучения. Перспективы: дообучение ruBERT на реальных транзакциях, иерархическая классификация, активное обучение для сложных пограничных случаев.

Литература

- [1] A. Joulin, E. Grave, P. Bojanowski, T. Mikolov. Bag of Tricks for Efficient Text Classification. EACL 2017.
- [2] X. Zhang, J. Zhao, Y. LeCun. Character-level Convolutional Networks for Text Classification. NeurIPS 2015.
- [3] J. Devlin, M.-W. Chang, K. Lee, K. Toutanova. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. NAACL 2019.
- [4] Y. Kuratov, M. Arkhipov. Adaptation of Deep Bidirectional Multilingual Transformers for Russian Language. arXiv:1905.07213, 2019.
- [5] T. Brown, B. Mann, N. Ryder et al. Language Models are Few-Shot Learners. NeurIPS 2020.
- [6] Сбербанк. GigaChat — российская языковая модель. <https://developers.sber.ru/portal/products/gigachat>, 2024.